

FAQ: Inteligencia Artificial en la Empresa

P: ¿Qué es un Modelo de Lenguaje Grande (LLM)?

R: Un LLM es un modelo de inteligencia artificial entrenado con grandes cantidades de texto para entender y generar lenguaje natural.

P: ¿Qué diferencia hay entre IA generativa y IA discriminativa?

R: La IA generativa crea nuevo contenido (texto, imágenes, código), mientras que la discriminativa clasifica o predice sobre datos existentes.

P: ¿Es seguro usar IA con datos corporativos?

R: Depende. Nunca enviar datos confidenciales a servicios públicos de IA. Usar modelos locales o privados para información sensible.

P: ¿Qué es RAG (Retrieval Augmented Generation)?

R: Es una técnica que permite a un LLM responder preguntas basándose en documentos específicos de la empresa, mejorando la precisión y reduciendo alucinaciones.

P: ¿Qué hardware se necesita para correr LLMs localmente?

R: Para modelos pequeños (3B-7B parámetros): GPU con 4-8GB VRAM. Para modelos medianos (13B): 16GB VRAM. Para grandes (70B): múltiples GPUs.

P: ¿Qué es el fine-tuning?

R: Es el proceso de reentrenar un modelo pre-entrenado con datos específicos de un dominio para mejorar su rendimiento en tareas particulares.

P: ¿Qué son los embeddings?

R: Son representaciones vectoriales de texto que capturan su significado semántico. Permiten búsquedas por similitud conceptual.

P: ¿Cómo se evalúa la calidad de un RAG?

R: Métricas comunes: faithfulness (la respuesta se basa en los documentos), answer relevance (relevancia de la respuesta), context precision (precisión del contexto recuperado).

P: ¿Qué es una alucinación en IA?

R: Es cuando un modelo genera información plausible pero incorrecta o inventada. El RAG ayuda a reducir este problema.

P: ¿Cuándo usar un agente de IA vs un RAG simple?

R: Usar RAG simple para preguntas sobre documentos. Usar agentes cuando se necesitan múltiples pasos, herramientas externas, o razonamiento complejo.